

ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



NGÀNH KHOA HỌC MÁY TÍNH
MÔN HỌC: TRUY VẤN THÔNG TIN ĐA PHƯƠNG TIỆN

**Tiêu đề: Cross-Modal Retrieval
Based On CLIP**

Học viên:

Trần Hà Sơn - 22521259
Lê Văn Hoàng - 22520465
Nguyễn Xuân Bách - 22520093

Giảng viên:

Đỗ Văn Tiến

1 Giới thiệu về bài toán

Trong bài toán truy vấn ảnh và văn bản, mục tiêu là tìm kiếm hình ảnh/văn bản khi người dùng input một tấm ảnh hoặc một câu query. Đây là một bài toán điển hình trong lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP) kết hợp với Nhận diện hình ảnh (Computer Vision), có ứng dụng rộng rãi trong nhiều lĩnh vực như tìm kiếm hình ảnh trên web, phân tích dữ liệu hình ảnh, và hỗ trợ truy vấn thông minh.

2 Dữ liệu

2.1 COCO-2017



Figure 1: COCO dataset

Trong dự án này, chúng ta sử dụng dataset COCO 2017 để xây dựng một hệ thống có khả năng truy vấn ảnh và văn bản. Dataset COCO (Common Objects in Context) là một bộ dữ liệu lớn bao gồm hàng triệu hình ảnh được gắn nhãn với các đối tượng, mô tả, và phân loại khác nhau. Bộ dữ liệu này cũng chứa các chú thích (captions) cho từng ảnh, giúp kết nối hình ảnh với các mô tả văn bản, điều này tạo ra một cơ sở dữ liệu phong phú để thực hiện các bài toán như tìm kiếm ảnh bằng văn bản (text-to-image retrieval) và tìm kiếm văn bản mô tả từ ảnh (image-to-text retrieval).

2.2 Human Face

Với sự phát triển mạnh mẽ của công nghệ, nhận dạng khuôn mặt đã trở thành một ứng dụng quen thuộc trong cuộc sống hiện đại. Bộ dữ liệu này, bao gồm 7219 ảnh chân dung được lấy từ Kaggle, cung cấp một tập hợp đa

dạng các khuôn mặt nam và nữ, với sự tập trung đặc biệt vào hình ảnh người cao tuổi. Việc bổ sung một số khuôn mặt giả được thiết kế tỉ mỉ giúp hệ thống được huấn luyện có khả năng nhận diện tốt hơn trên nhiều loại hình ảnh đầu vào phức tạp.

3 Định nghĩa

3.1 CLIP




Figure 2: Enter Caption

CLIP (Contrastive Language-Image Pretraining) là một mô hình học sâu được phát triển bởi OpenAI, kết hợp giữa hai lĩnh vực chính là xử lý ngôn ngữ tự nhiên và nhận diện hình ảnh. Mô hình CLIP có khả năng học các đặc trưng của hình ảnh và văn bản trong không gian chung, giúp thực hiện các nhiệm vụ như truy vấn hình ảnh từ văn bản (text-to-image retrieval) và truy vấn văn bản từ hình ảnh (image-to-text retrieval).

Trong bối cảnh bài toán kết nối hình ảnh và văn bản, CLIP-ViT-B-32 là một phiên bản của CLIP được xây dựng dựa trên kiến trúc Vision Transformer (ViT). ViT đã trở thành một trong những kiến trúc nổi bật trong các tác vụ nhận diện hình ảnh nhờ vào khả năng học các đặc trưng phức tạp từ hình ảnh qua các cơ chế tự chú ý (self-attention). CLIP kết hợp Vision Transformer với một mô hình ngôn ngữ học sâu để học đồng thời các đặc trưng hình ảnh và văn bản.

3.2 Semantic Search

Semantic Search (Tìm kiếm ngữ nghĩa) là một phương pháp tìm kiếm thông minh, nhằm nâng cao chất lượng kết quả tìm kiếm bằng cách hiểu nghĩa thực sự của các truy vấn và nội dung tìm kiếm, thay vì chỉ dựa vào từ khóa chính xác. Thay vì chỉ khớp các từ tìm kiếm với văn bản trong cơ sở dữ liệu, Semantic Search cố gắng hiểu mối quan hệ, ngữ cảnh và ý nghĩa của các từ trong truy vấn và tài liệu. Trong bài toán này bọn em dùng mô hình CLIP để hiểu ngữ nghĩa của văn bản truy vấn đầu vào.

3.3 FAISS

Faiss (Facebook AI Similarity Search) là một thư viện mã nguồn mở được phát triển bởi Facebook AI Research (FAIR) với mục đích cung cấp các công cụ tối ưu cho việc tìm kiếm các đối tượng giống nhau trong không gian vector. Faiss được thiết kế để tìm kiếm và phân nhóm dữ liệu nhanh chóng, đặc biệt trong các ứng dụng yêu cầu tìm kiếm các vector tương tự (nearest neighbor search) với hiệu suất cao và khả năng xử lý lượng lớn dữ liệu.

Faiss là một công cụ cực kỳ hữu ích trong các hệ thống tìm kiếm ngữ nghĩa và học máy, nơi mà các đối tượng (hình ảnh, văn bản, v.v.) được chuyển thành các vector nhúng (embeddings) và cần được tìm kiếm nhanh chóng trong cơ sở dữ liệu lớn.

Cách FAISS Hoạt Động:

Bước 1: Chuyển đổi dữ liệu thành vector nhúng(embedding) bằng các mô hình nhúng như CLIP.

Bước 2: Lưu trữ các vector này vào chỉ mục FAISS để tối ưu hóa cho tìm kiếm lân cận.

Bước 3: Khi có truy vấn đầu vào, FAISS sẽ chuyển đổi truy vấn thành vector và tìm kiếm các vector gần nhất.

Hỗ trợ nhiều loại chỉ mục: -IndexFlatL2: Tìm kiếm dựa trên khoảng cách Euclidean. -IndexFlatIP: Tìm kiếm dựa trên cosine similarity hoặc tích vô hướng (inner product). -IVF (Inverted File Index): Tăng tốc độ tìm kiếm bằng cách chia dữ liệu thành nhiều cụm nhỏ.

Ở đây bọn em tìm kiếm truy vấn dựa trên độ đo cosine(IndexFlatIP)




Figure 3: Enter Caption

3.4 Django

Django là một framework phát triển web mã nguồn mở viết bằng Python, được thiết kế để giúp việc phát triển các ứng dụng web trở nên nhanh chóng, dễ dàng và hiệu quả. Được ra đời vào năm 2005, Django đã nhanh chóng trở thành một trong những framework phổ biến nhất trong cộng đồng lập trình web nhờ vào sự mạnh mẽ, tính bảo mật cao và khả năng mở rộng linh hoạt.

Django áp dụng nguyên tắc "Don't Repeat Yourself" (DRY), giúp giảm thiểu mã nguồn lặp lại và dễ dàng duy trì, từ đó tăng hiệu quả lập trình. Ngoài ra, Django còn tuân thủ nguyên tắc "The Reusable Components", giúp lập trình viên tái sử dụng các thành phần và mô-đun trong các dự án khác nhau.

4 Pipeline

4.1 COCO dataset

Trong dự án này, chúng em sẽ sử dụng bộ dataset COCO (Common Objects in Context), một bộ dữ liệu lớn và phổ biến trong lĩnh vực thị giác máy tính và xử lý ngôn ngữ tự nhiên. Bộ dataset COCO bao gồm 118,000 ảnh, mỗi ảnh đi kèm với các mô tả (caption) chi tiết. Để thực hiện tìm kiếm theo đặc trưng ngữ nghĩa (semantic search), chúng em sẽ sử dụng mô hình CLIP (Contrastive Language-Image Pretraining) của OpenAI, cụ thể là phiên bản ViT-B-32 (Vision Transformer với kiến trúc base 32 lớp), để tạo ra các vector embedding từ các caption của ảnh. Các vector embedding này sau đó sẽ được lưu trữ trong FAISS, một thư viện hiệu quả cho việc tìm kiếm tương đồng nhanh (similarity search) trên các không gian vector lớn.




Figure 4: Pipeline for COCO

Workflow chi tiết

1. Tạo vector embedding cho các caption của ảnh:

- Đầu tiên, chúng em sẽ sử dụng mô hình CLIP để biến đổi các caption của ảnh trong dataset COCO thành các vector embedding. CLIP là một mô hình đa phương thức (multimodal) được huấn luyện để hiểu mối quan hệ giữa văn bản và hình ảnh, do đó nó có khả năng biểu diễn cả văn bản và hình ảnh trong cùng một không gian vector.
- Với mỗi caption, CLIP sẽ tạo ra một vector embedding có kích thước cố định (ví dụ: 512 chiều), biểu diễn đặc trưng ngữ nghĩa của caption đó. Các vector này sẽ được sử dụng để thực hiện tìm kiếm dựa trên ngữ nghĩa thay vì từ khóa đơn thuần.

2. Lưu trữ vector embedding trong FAISS:

- Sau khi tạo ra các vector embedding từ caption, chúng em sẽ lưu trữ chúng trong một chỉ mục FAISS. FAISS là một thư viện được phát triển bởi Facebook AI, cho phép tìm kiếm tương đồng nhanh chóng trên các tập dữ liệu lớn với hàng triệu hoặc thậm chí hàng tỷ vector.
- FAISS sử dụng các kỹ thuật tối ưu hóa như lượng tử hóa (quantization) và tìm kiếm gần đúng (approximate nearest neighbor search) để giảm thời gian tìm kiếm mà vẫn đảm bảo độ chính xác.

cao. Điều này đặc biệt hữu ích khi làm việc với các bộ dữ liệu lớn như COCO.

3. Truy vấn dựa trên text hoặc image input:

- Khi có một truy vấn đầu vào (query), có thể là một đoạn văn bản (text) hoặc một hình ảnh (image), chúng em sẽ sử dụng CLIP để biến đổi truy vấn này thành một vector embedding tương ứng.
- Nếu truy vấn là văn bản, CLIP sẽ sử dụng text encoder để tạo ra vector embedding. Nếu truy vấn là hình ảnh, CLIP sẽ sử dụng image encoder để tạo ra vector embedding.
- Vector embedding của truy vấn sau đó sẽ được so sánh với các vector embedding đã được lưu trữ trong FAISS dựa trên độ đo cosine similarity. Cosine similarity là một độ đo phổ biến để đánh giá sự tương đồng giữa hai vector, với giá trị nằm trong khoảng từ -1 đến 1. Giá trị càng gần 1 thì hai vector càng tương đồng.

4. Kết quả tìm kiếm:

- FAISS sẽ trả về các kết quả tìm kiếm là các vector embedding có độ tương đồng cao nhất với vector embedding của truy vấn. Các kết quả này có thể là các caption hoặc hình ảnh tương ứng trong dataset COCO.
- Nhờ vào khả năng tìm kiếm nhanh chóng và hiệu quả của FAISS, chúng em có thể thực hiện tìm kiếm ngữ nghĩa trên bộ dữ liệu lớn một cách dễ dàng và chính xác.

Tóm tắt

- **Dataset COCO:** 118,000 ảnh với các caption chi tiết.
- **CLIP (ViT-B-32):** Sử dụng để tạo vector embedding cho caption và truy vấn (text hoặc image).
- **FAISS:** Lưu trữ vector embedding và thực hiện tìm kiếm tương đồng nhanh dựa trên cosine similarity.
- **Workflow:**

1. Embed caption bằng CLIP.
2. Lưu trữ embedding trong FAISS.
3. Embed truy vấn (text/image) bằng CLIP.
4. Tìm kiếm tương đồng trong FAISS.

4.2 Human Face dataset




Figure 5: Pipeline for COCO

Trong phần này, chúng em sẽ áp dụng phương pháp tương tự nhưng thay vì sử dụng caption của ảnh, chúng em sẽ embed trực tiếp hình ảnh khuôn mặt từ một bộ dataset khuôn mặt (human face dataset). Cụ thể, chúng em sẽ sử dụng mô hình CLIP để tạo vector embedding trực tiếp từ hình ảnh khuôn mặt và lưu trữ chúng trong FAISS để thực hiện tìm kiếm tương đồng.

Workflow chi tiết

1. Tạo vector embedding cho hình ảnh khuôn mặt:

- Đầu tiên, chúng em sẽ sử dụng mô hình CLIP để biến đổi các hình ảnh khuôn mặt trong dataset thành các vector embedding. CLIP có khả năng xử lý hình ảnh và biểu diễn chúng trong không gian vector.

- Với mỗi hình ảnh khuôn mặt, CLIP sẽ tạo ra một vector embedding có kích thước cố định (ví dụ: 512 chiều), biểu diễn đặc trưng của khuôn mặt đó. Các vector này sẽ được sử dụng để thực hiện tìm kiếm dựa trên đặc trưng hình ảnh.

2. Lưu trữ vector embedding trong FAISS:

- Sau khi tạo ra các vector embedding từ hình ảnh khuôn mặt, chúng em sẽ lưu trữ chúng trong một chỉ mục FAISS. FAISS cho phép tìm kiếm tương đồng nhanh chóng trên các tập dữ liệu lớn.
- FAISS sử dụng các kỹ thuật tối ưu hóa như lượng tử hóa (quantization) và tìm kiếm gần đúng (approximate nearest neighbor search) để giảm thời gian tìm kiếm mà vẫn đảm bảo độ chính xác cao.

3. Truy vấn dựa trên hình ảnh khuôn mặt:

- Khi có một truy vấn đầu vào là một hình ảnh khuôn mặt hoặc một mô tả về khuôn mặt, chúng em sẽ sử dụng CLIP để biến đổi hình ảnh/mô tả này thành một vector embedding tương ứng.
- Vector embedding của truy vấn sau đó sẽ được so sánh với các vector embedding đã được lưu trữ trong FAISS dựa trên độ đo cosine similarity. Cosine similarity là một độ đo phổ biến để đánh giá sự tương đồng giữa hai vector, với giá trị nằm trong khoảng từ -1 đến 1. Giá trị càng gần 1 thì hai vector càng tương đồng.

4. Kết quả tìm kiếm:

- FAISS sẽ trả về các kết quả tìm kiếm là các vector embedding có độ tương đồng cao nhất với vector embedding của truy vấn. Các kết quả này có thể là các hình ảnh khuôn mặt tương ứng trong dataset.
- Nhờ vào khả năng tìm kiếm nhanh chóng và hiệu quả của FAISS, chúng em có thể thực hiện tìm kiếm tương đồng trên bộ dữ liệu lớn một cách dễ dàng và chính xác.

Tóm tắt

- **Human Face Dataset:** Bộ dữ liệu khuôn mặt với các hình ảnh khuôn mặt.

- **CLIP (ViT-B-32)**: Sử dụng để tạo vector embedding trực tiếp từ hình ảnh khuôn mặt.
- **FAISS**: Lưu trữ vector embedding và thực hiện tìm kiếm tương đồng nhanh dựa trên cosine similarity.
- **Workflow**:
 1. Embed hình ảnh khuôn mặt bằng CLIP.
 2. Lưu trữ embedding trong FAISS.
 3. Embed truy vấn (hình ảnh khuôn mặt hoặc mô tả khuôn mặt) bằng CLIP.
 4. Tìm kiếm tương đồng trong FAISS.

5 Thực nghiệm

5.1 COCO dataset



Figure 6: Query




Figure 7: Result

Figure 8: CLIP hiểu mối quan hệ động vật xung đột trên tuyết

Khi query là: **a beautiful view** sẽ cho ra kết quả như sau:




Figure 9: Results

Lưu ý quan trọng: Trong trường hợp sử dụng COCO dataset, chúng em thực hiện embedding các caption (mô tả) đi kèm với hình ảnh thay vì embedding trực tiếp hình ảnh. Điều này đôi khi dẫn đến kết quả truy vấn không hoàn toàn phù hợp với hình ảnh thực tế. Ví dụ, với truy vấn như "*a beautiful view*", mô hình sẽ ưu tiên tìm kiếm các caption có nội dung tương ứng thay vì tập trung vào đặc điểm trực quan của hình ảnh. Đây là một hạn chế cần lưu tâm khi áp dụng phương pháp này, đặc biệt trong các tác vụ yêu cầu độ chính xác cao về mặt hình ảnh.

5.2 Human Face dataset



Figure 10: Query




Figure 11: Result

Figure 12: Khá tốt, có một số bộ phân khá giống (lông mày)

Khi truy vấn là văn bản, ứng dụng này trở nên vô cùng thú vị và hữu ích,

đặc biệt trong các tình huống thực tế như tìm kiếm người dựa trên mô tả đặc điểm nhận dạng. Ví dụ, với truy vấn như *"a man with bushy eyebrows, a high nose, and a beard"*, hệ thống sẽ nhanh chóng trả về các kết quả hình ảnh phù hợp dựa trên mô tả chi tiết. Điều này không chỉ mang lại tiện ích trong việc tìm kiếm thông thường mà còn có thể ứng dụng trong các lĩnh vực quan trọng như hỗ trợ điều tra hình sự, giúp xác định đối tượng nghi vấn một cách nhanh chóng và chính xác.




Figure 13: Results

6 Phân chia công việc

Nhiệm vụ	Lê Văn Hoàng	Trần Hà Sơn	Nguyễn Xuân Bách
Thu thập dữ liệu	x	x	
Viết slide			x
Viết report	x	x	x
Xây dựng mô hình	x	x	
Backend, Frontend	x	x	x

Figure 14: Bảng phân chia nhiệm vụ

7 Kết luận

Dự án này đã khai thác hiệu quả sức mạnh của mô hình CLIP và thư viện FAISS để xây dựng một hệ thống tìm kiếm đa phương thức linh hoạt và mạnh mẽ. Bằng cách embedding cả văn bản và hình ảnh vào cùng một không gian vector, chúng ta có thể thực hiện tìm kiếm ngữ nghĩa một cách chính xác và nhanh chóng, từ việc tìm kiếm hình ảnh dựa trên mô tả văn bản đến việc truy vấn hình ảnh dựa trên đặc điểm trực quan.

Ứng dụng này không chỉ mang lại tiện ích trong việc tìm kiếm thông tin thông thường mà còn mở ra nhiều tiềm năng trong các lĩnh vực thực tế như an ninh, điều tra hình sự, hoặc quản lý dữ liệu đa phương thức. Tuy nhiên, vẫn còn một số hạn chế cần được cải thiện, chẳng hạn như độ chính xác khi truy vấn dựa trên caption thay vì hình ảnh trực tiếp.

Trong tương lai, chúng ta có thể nâng cấp hệ thống bằng cách tích hợp thêm các mô hình chuyên sâu hơn cho việc nhận dạng hình ảnh hoặc cải thiện chất lượng embedding để tăng độ chính xác của kết quả tìm kiếm. Dự án này không chỉ là một minh chứng cho sức mạnh của AI trong xử lý dữ liệu đa phương thức mà còn là nền tảng cho nhiều ứng dụng thú vị và thiết thực trong tương lai.